

基于 NOAI 2026 学术大纲 V1.5

NOAI人工智能竞赛 授课大纲

全面覆盖A/B/C/D四大考核区域
涵盖全部考点与核心知识点

本大纲严格对标NOAI 2026年学术大纲，系统设计14个教学模块、共92课时，涵盖Python编程基础、数学基础、机器学习方法范式、神经网络与深度学习、数据处理工具、PyTorch实践、计算机视觉、自然语言处理、语音处理与大语言模型等全部竞赛考点，助力选手高效备考。

课程定位：NOAI竞赛备考培训

适用对象：高中生 / 竞赛选手

参考材料：《动手学深度学习》/ IAO Training Guide / IOAI Syllabus 2025

目录

模块一 课程导论与竞赛概述	5
1.1 NOAI竞赛介绍	5
1.2 人工智能发展简史	5
1.3 课程学习方法与备考策略	5
模块二 Python编程基础	6
2.1 Python基本语法	6
2.2 程序控制结构	6
2.3 基本数据结构	7
2.4 函数、模块与包	7
2.5 算法基础与第三方库使用	7
模块三 人工智能伦理与概述	8
3.1 人工智能的基本概念	8
3.2 AI伦理与安全	8
模块四 数学基础	8
4.1 概率论基础	8
4.2 统计学基础	9
4.3 距离度量	9
4.4 线性与非线性	9

模块五 机器学习方法范式	10
5.1 监督学习 (Supervised Learning)	10
5.2 无监督学习 (Unsupervised Learning)	10
5.3 强化学习 (Reinforcement Learning)	10
5.4 数据基础	11
模块六 监督学习核心算法	11
6.1 线性回归 (Linear Regression)	11
6.2 逻辑回归 (Logistic Regression)	11
6.3 其他常见算法概述	11
6.4 集成学习 (Model Ensembles)	12
模块七 模型评估与优化	12
7.1 分类评估指标	12
7.2 交叉验证	12
7.3 过拟合、欠拟合与正则化	13
模块八 神经网络基础	13
8.1 感知机与神经网络概述	13
8.2 误差反向传播 (Backpropagation, BP)	13
8.3 梯度下降与优化方法	14
8.4 激活函数、损失函数与决策函数	14
8.5 大语言模型概述	14
模块九 卷积神经网络	15

9.1 卷积神经网络基本原理	15
9.2 神经网络常用层的原理与计算	15
模块十 数据处理与可视化工具	15
10.1 NumPy数据处理	15
10.2 Pandas数据分析	16
10.3 Matplotlib数据可视化	16
10.4 特征工程技术	16
模块十一 PyTorch深度学习实践	17
11.1 PyTorch基础语法	17
11.2 神经网络定义与训练	17
11.3 CPU与GPU训练	17
11.4 权重初始化与批量归一化	17
11.5 RNN与GAN基础	18
模块十二 计算机视觉	18
12.1 图像分割 (Image Segmentation)	18
12.2 目标检测 (Object Detection)	18
12.3 特征提取 (Feature Extraction)	19
模块十三 自然语言处理	19
13.1 文本预处理与词法分析	19
13.2 文本分类与词嵌入	19
13.3 Transformer与预训练模型	20

模块十四 语音处理与大语言模型	20
14.1 语音信号处理	20
14.2 生成式人工智能与大语言模型	20
14.3 综合实践与竞赛模拟	20

模块一 课程导论与竞赛概述

1.1 NOAI竞赛介绍

NOAI (National Olympiad in Artificial Intelligence) 是面向高中生的人工智能学术竞赛，旨在培养青少年对人工智能领域的理论理解与实践能力。竞赛分为两轮：第一轮为水平测试轮（笔试），考查A区（一般计算机技能）和B区（人工智能基础知识）；第二轮为人工智能应用实践轮，考查C区（进阶计算机技能）和D区（人工智能进阶知识与技能）。本课程严格对标NOAI 2026年学术大纲V1.5，全面覆盖所有考点，帮助选手进行系统化的备考准备。

1.2 人工智能发展简史

本节从人工智能的诞生讲起，涵盖符号主义、连接主义与行为主义三大流派的核心思想与发展脉络。重点介绍图灵测试的历史意义、感知机的发明与局限、专家系统的兴衰、反向传播算法的复兴、统计学习方法的崛起，以及大数据与GPU计算推动的深度学习革命。最后介绍Transformer架构和大语言模型（LLM）如何改变了人工智能的技术格局与应用范式。

- 符号主义 (Symbolism)、连接主义 (Connectionism)、行为主义 (Behaviourism) 的基本主张与代表成果
- 图灵测试 (Turing Test) 的定义、意义及局限性
- 深度学习革命：从多层感知机到Transformer
- 大语言模型时代的来临：从GPT到多模态AI

1.3 课程学习方法与备考策略

本节介绍课程的整体安排和学习建议，包括各模块的知识权重分配、理论部分与实践部分的学习方法、推荐参考书目（如《动手学深度学习》(d2l-zh-pytorch)、IAIO Training Guide等），以及历年真题与模拟练习的使用策略。帮助学生建立高效的学习计划，合理分配时间，重点突破薄弱环节。

模块	内容领域	对应大纲	建议课时
模块一	课程导论与竞赛概述	A/B/C/D综合	2课时
模块二	Python编程基础	A区	6课时
模块三	人工智能伦理与概述	B区	2课时
模块四	数学基础	B区	6课时
模块五	机器学习方法范式	B区	8课时

模块六	监督学习核心算法	B区	10课时
模块七	模型评估与优化	B区	6课时
模块八	神经网络基础	B区	8课时
模块九	卷积神经网络	B区	6课时
模块十	数据处理与可视化工具	C区	8课时
模块十一	PyTorch深度学习实践	D区	10课时
模块十二	计算机视觉	D区	6课时
模块十三	自然语言处理	D区	6课时
模块十四	语音处理与大语言模型	D区	6课时
合计			92课时

表1 课程模块总览

模块二 Python编程基础

本模块涵盖NOAI大纲A区"一般计算机技能"的全部要求，确保选手具备最基本的Python编程能力，能够使用Python编写程序解决实际问题，包括简单数据处理和算法问题。本模块是后续所有实践课程的基础。

2.1 Python基本语法

本节系统讲解Python语言的基本语法结构，从变量与数据类型入手，逐步深入到表达式与运算符的使用。重点掌握算术运算、关系运算（比较运算）和逻辑运算，理解运算符优先级规则。同时涵盖输入输出语句（input/print）的使用，以及Python代码的编码规范与注释写法。通过大量练习题巩固语法基础。

- 变量命名规则、基本数据类型（int, float, bool, str）及其转换
- 算术运算符（+、-、*、/、//、%、**）、关系运算符与逻辑运算符
- 输入函数input()与输出函数print()的格式化使用
- 字符串格式化方法：f-string、format()、百分号格式化

2.2 程序控制结构

程序控制结构是编程的核心要素，本节详细讲解顺序结构、分支结构和循环结构三大基本程序结构。通过丰富的案例和练习，帮助学生掌握条件判断和循环控制的使用技巧，理解流程控制的基本逻辑，能够独立编写具有一定复杂度的程序来解决实际问题。

- 顺序结构、分支结构 (if/elif/else) 与嵌套条件判断
- 循环结构 (for循环、while循环)、循环控制 (break/continue)
- 循环嵌套与常见编程模式 (累加、查找、遍历等)

2.3 基本数据结构

数据结构是组织和存储数据的方式。本节深入讲解Python中四种最重要的内置数据结构：字符串 (String)、列表 (List)、字典 (Dictionary) 和元组 (Tuple)。每种数据结构都将从创建方式、基本操作 (增删改查)、常用方法、遍历方式等方面进行系统讲解，并辅以大量实践练习。

- 字符串操作：索引、切片、拼接、查找、替换、分割与常用方法
- 列表操作：创建、追加、插入、删除、排序、切片、列表推导式
- 字典操作：键值对管理、遍历、嵌套字典、常用方法
- 元组操作：不可变序列的特性与使用场景

2.4 函数、模块与包

函数是代码复用的基本单位，模块和包是代码组织的高级形式。本节从函数的定义与调用讲起，涵盖参数传递 (位置参数、关键字参数、默认参数、可变参数)、返回值、作用域等核心概念。然后介绍模块的导入方式 (import语句) 和包的结构，重点掌握os、math、random、sys等标准库模块的常用功能。

- 自定义函数：def语句、参数类型、返回值、lambda表达式
- 变量作用域：局部变量与全局变量、LEGB规则
- 模块导入与使用：import、from...import、常用标准库 (os, math, random, sys)
- 包的结构与__init__.py文件的作用

2.5 算法基础与第三方库使用

本节讲解基本的算法思想与实现，包括排序算法 (冒泡排序、选择排序、插入排序) 和查找算法 (线性查找、二分查找) 的原理与代码实现。同时培养学生在文档帮助下使用第三方库解决问题的能力，这是NOAI竞赛中非常重要的实践技能。

- 排序算法：冒泡排序、选择排序、插入排序的原理与Python实现
- 查找算法：线性查找与二分查找 (Binary Search)
- 阅读和理解代码的基本能力训练
- 在文档帮助下使用第三方库 (如pip install与import使用)

模块三 人工智能伦理与概述

本模块对应NOAI大纲B区中"人工智能概述"部分，帮助学生建立对人工智能领域的宏观认知，理解AI技术发展带来的伦理挑战与社会影响，树立正确的价值观和责任意识。

3.1 人工智能的基本概念

从人工智能的定义出发，系统介绍三大AI流派的核心思想：符号主义强调逻辑推理与知识表示，连接主义以神经网络模拟大脑运作机制，行为主义关注智能体与环境的交互学习。通过案例分析和对比讨论，帮助学生理解不同流派的历史背景、核心贡献和适用领域。

- 连接主义 (Connectionism)：神经网络、感知机、深度学习的发展脉络
- 符号主义 (Symbolism)：专家系统、知识图谱、逻辑推理
- 行为主义 (Behaviourism)：强化学习、机器人控制
- 图灵测试 (Turing Test)：定义、历史意义与局限性探讨

3.2 AI伦理与安全

人工智能技术的广泛应用带来了诸多伦理挑战和安全风险。本节通过大量真实案例分析，帮助学生理解数据隐私保护、算法偏见与公平性、AI责任归属等关键议题。通过小组讨论和案例分析，培养学生的批判性思维，使其能够在实际应用场景中识别和应对AI伦理问题。

- 数据隐私 (Data Privacy)：个人数据收集、存储与使用的伦理边界
- 算法偏见 (Algorithmic Bias)：训练数据偏差导致的歧视性问题及其成因
- AI责任归属：自动驾驶事故、医疗AI误诊等场景的责任划分
- 案例分析：图像搜索偏见、招聘算法偏见、预测性执法等典型案例
- 应对措施：偏差检测与缓解、公平性定义、透明度与可解释性

模块四 数学基础

本模块提供机器学习所需的数学基础知识，涵盖概率论、统计学和距离度量等核心概念。这些数学工具是理解后续机器学习算法原理的基础，也是NOAI大纲B区明确要求的考核内容。课程注重概念的直观理解而非严格证明，配合Python代码演示帮助学生在实践中掌握数学知识。

4.1 概率论基础

概率论是机器学习理论的数学基石。本节从概率的基本定义出发，系统讲解条件概率、贝叶斯定理等核心概念，并介绍机器学习中常用的概率分布。通过具体实例（如医疗检测、垃圾邮件分类等）帮助学生理解概率推理的实际应用。

- 概率的基本概念：样本空间、事件、概率公理

- 条件概率 (Conditional Probability) 与独立性的定义
- 贝叶斯定理 (Bayes' Theorem) 及其在机器学习中的应用
- 常见概率分布：伯努利分布、二项分布、正态分布 (高斯分布)
- 期望 (Expected Value) 与方差 (Variance) 的计算与意义

4.2 统计学基础

统计学是数据分析和模型评估的重要工具。本节涵盖描述统计和推断统计的基本概念，重点讲解机器学习中频繁使用的统计量，包括残差、偏差和标准差等。通过实际数据集的统计分析练习，帮助学生建立数据处理的基本直觉。

- 描述统计量：均值、中位数、众数、分位数
- 残差 (Residual)：定义、计算与在回归分析中的作用
- 偏差 (Bias)：估计量偏差与模型偏差的区别
- 标准差 (Standard Deviation)：计算方法与数据离散程度的度量
- 相关系数与协方差：变量间线性关系的度量

4.3 距离度量

距离度量是许多机器学习算法 (如K近邻、K-Means聚类) 的核心计算工具。本节系统讲解常见的距离定义和相似性度量方法，帮助学生理解不同距离度量的数学形式和适用场景。

- 欧氏距离 (Euclidean Distance)：L2范数的定义与计算
- 曼哈顿距离 (Manhattan Distance)：L1范数
- 明可夫斯基距离 (Minkowski Distance)：L1和L2的推广
- 余弦相似度 (Cosine Similarity)：文本相似度计算中的常用度量
- 汉明距离 (Hamming Distance)：用于分类错误的度量

4.4 线性与非线性

理解线性与非线性是区分不同机器学习方法的基础。本节从数学角度解释线性的定义，介绍线性函数、线性变换和线性可分性的概念，并与非线性方法进行对比。结合具体案例 (如线性回归vs多项式回归、线性核vs RBF核) 帮助学生直观理解两者的本质区别。

- 线性关系与线性变换的数学定义
- 线性可分性 (Linear Separability) 与分类问题
- 非线性问题的特征与非线性方法 (核方法、激活函数)

模块五 机器学习方法范式

本模块系统介绍机器学习的三大方法范式：监督学习、无监督学习和强化学习。帮助学生理解每种范式的核心思想、适用问题类型、训练与推理过程，以及各范式之间的区别与联系。这是NOAI大纲B区的核心要求之一。

5.1 监督学习 (Supervised Learning)

监督学习是最广泛使用的机器学习范式。本节从监督学习的基本框架出发，讲解训练数据（特征+标签）的结构，介绍两大任务类型：回归（预测连续值）和分类（预测离散类别）。帮助学生理解模型训练的过程本质是利用标注数据学习输入到输出的映射关系。

- 监督学习的基本框架：训练集、特征、标签、模型、预测
- 回归任务 (Regression)：预测连续值输出（如房价预测、温度预测）
- 分类任务 (Classification)：预测离散类别（如图像分类、垃圾邮件检测）
- 训练与推理过程：前向传播、损失计算、参数更新、预测推理
- 回归与分类的常见算法概览

5.2 无监督学习 (Unsupervised Learning)

无监督学习处理没有标注标签的数据，旨在发现数据中的内在结构和模式。本节重点介绍聚类任务 (Clustering)，讲解其目标是将数据样本按照相似性划分为若干组。同时简要介绍降维等其他无监督学习任务，帮助学生理解无监督学习的数据探索和特征发现功能。

- 无监督学习的基本思想：无标签数据下的模式发现
- 聚类 (Clustering)：将相似样本分组，常见算法包括K-Means、层次聚类
- 降维 (Dimensionality Reduction)：主成分分析 (PCA)、t-SNE
- 监督学习与无监督学习的区别与联系

5.3 强化学习 (Reinforcement Learning)

强化学习是智能体通过与环境交互来学习最优策略的方法。本节介绍强化学习的基本框架，包括智能体、环境、状态、动作、奖励等核心概念，以及马尔可夫决策过程 (MDP) 的基本思想。帮助学生理解强化学习与监督学习的本质区别，了解其在游戏、机器人控制、自动驾驶等领域的典型应用场景。

- 强化学习框架：智能体 (Agent)、环境 (Environment)、状态 (State)、动作 (Action)、奖励 (Reward)
- 探索与利用 (Exploration vs. Exploitation) 的权衡
- 典型应用场景：游戏AI (AlphaGo)、机器人路径规划、推荐系统

5.4 数据基础

数据是机器学习的核心要素。本节系统讲解数据清洗的一般过程和训练集、验证集、测试集的划分方法。帮助学生理解高质量数据对模型性能的重要性，掌握常见的数据预处理技术。

- 数据清洗 (Data Cleaning)：缺失值处理、异常值检测、重复数据去除
- 训练集 (Training Set)、验证集 (Validation Set)、测试集 (Testing Set) 的划分原则
- 数据划分比例与交叉验证的必要性
- 数据质量对模型性能的影响分析

模块六 监督学习核心算法

本模块深入讲解NOAI大纲B区要求的几种核心监督学习算法，包括线性回归、逻辑回归，以及K近邻、决策树、支持向量机等常见分类算法。每种算法都从直观理解、数学原理和Python实践三个层面进行讲解。

6.1 线性回归 (Linear Regression)

线性回归是最基本的回归算法，也是理解更复杂模型的起点。本节从简单线性回归讲起，逐步扩展到多元线性回归。重点讲解假设函数、损失函数（均方误差MSE）的定义，以及如何通过梯度下降法求解最优参数。

- 线性回归的基本原理：假设函数 $h(x) = wx + b$
- 损失函数：均方误差 (MSE, Mean Squared Error) 的定义与计算
- 梯度下降法 (Gradient Descent) 求解参数的基本过程
- 多元线性回归与多项式回归

6.2 逻辑回归 (Logistic Regression)

逻辑回归是经典的二分类算法，名字中虽有"回归"二字，但本质是分类方法。本节讲解Sigmoid函数如何将线性输出映射到概率空间，以及逻辑回归的决策边界是如何形成的。通过实际案例（如疾病预测、信用评分）帮助学生理解其应用方式。

- 为什么线性回归不适合分类问题
- Sigmoid函数：将输出映射到 $[0, 1]$ 概率区间
- 逻辑回归假设函数与决策边界 (Decision Boundary)
- 交叉熵损失函数 (Cross Entropy Loss)

6.3 其他常见算法概述

本节简要介绍NOAI大纲中提到的其他常见监督学习算法，帮助学生了解各种算法的核心思想和适用场景。重点在于"知道"这些算法的存在和基本原理，能够在实际问题中选择合适的方法。

- K近邻算法 (K-Nearest Neighbors, K-NN)：基于距离的分类方法
- 决策树 (Decision Trees)：基于特征划分的树形分类结构
- 支持向量机 (Support Vector Machines, SVM)：最大间隔分类器
- 朴素贝叶斯分类 (Naive Bayes)：基于贝叶斯定理的概率分类

6.4 集成学习 (Model Ensembles)

集成学习通过组合多个基学习器来提升模型的泛化性能。本节介绍集成学习的核心思想，重点讲解Bagging方法和梯度提升 (Gradient Boosting) 方法，以及随机森林 (Random Forest) 的构建原理。

- 集成学习的核心思想：弱学习器组合为强学习器
- Bagging方法：并行训练多个独立模型，投票或平均输出
- 梯度提升 (Gradient Boosting)：串行训练，后续模型修正前面模型的错误
- 随机森林 (Random Forest)：Bagging + 特征随机选择

模块七 模型评估与优化

本模块对应NOAI大纲B区中关于模型评估的核心要求，涵盖评估指标的计算与选择、交叉验证方法、过拟合与欠拟合的诊断与处理，以及正则化等模型优化技术。这是衡量选手能否"根据实际场景选取或设计合适的模型评估指标"的关键模块。

7.1 分类评估指标

分类模型的评估需要从多个维度综合考量。本节系统讲解混淆矩阵及由其导出的各项指标：精确率、准确率、召回率和F1分数。帮助学生理解每个指标的计算方式、含义和适用场景，能够在不同业务需求下选择最合适的评估指标。

- 混淆矩阵 (Confusion Matrix)：真正例、假正例、假负例、真负例
- 准确率 (Accuracy) = $(TP + TN) / (TP + TN + FP + FN)$
- 精确率 (Precision) = $TP / (TP + FP)$
- 召回率 (Recall) = $TP / (TP + FN)$
- F1分数 (F1-Score)：精确率与召回率的调和平均
- 不同场景下评估指标的选择策略 (如医疗诊断优先召回率、垃圾邮件检测优先精确率)

7.2 交叉验证

交叉验证是评估模型泛化能力的可靠方法。本节讲解K折交叉验证的基本原理和实施步骤，帮助学生理解为什么单次训练-测试划分可能不够可靠，以及交叉验证如何更充分地利用有限数据。

- 交叉验证 (Cross Validation) 的目的与意义
- K折交叉验证 (K-Fold Cross Validation) 的实施步骤
- 交叉验证在超参数选择中的应用

7.3 过拟合、欠拟合与正则化

过拟合和欠拟合是机器学习中最常见的问题。本节帮助学生理解两者的本质区别、产生原因和表现形式，掌握偏差-方差权衡 (Bias-Variance Trade-off) 的核心概念。介绍正则化技术 (L1/L2正则化) 如何通过约束模型复杂度来防止过拟合。

- 欠拟合 (Underfitting)：模型过于简单，训练误差和测试误差都偏高
- 过拟合 (Overfitting)：模型过于复杂，训练误差低但测试误差高
- 偏差-方差权衡 (Bias-Variance Trade-off) 的基本思想
- 正则化 (Regularization)：L1正则化 (Lasso) 与L2正则化 (Ridge) 的原理与区别

模块八 神经网络基础

本模块对应NOAI大纲B区中"神经网络"部分的全部内容，从最简单的感知机出发，逐步深入到多层神经网络、误差反向传播算法和梯度下降优化方法。这是理解深度学习的理论基础，也是衔接第一轮笔试和第二轮实践的关键桥梁。

8.1 感知机与神经网络概述

感知机是最简单的神经网络模型，也是理解深度学习的起点。本节从单层感知机的结构讲起，介绍其输入、权重、偏置和激活的基本概念。然后扩展到多层感知机 (MLP)，讲解隐藏层的作用和网络的前向传播过程。

- 感知机 (Perceptron) 的结构与数学表达： $y = f(w \cdot x + b)$
- 多层感知机 (Multi-Layer Perceptron, MLP) 的层结构
- 神经网络的基本组成：输入层、隐藏层、输出层

8.2 误差反向传播 (Backpropagation, BP)

反向传播算法是训练神经网络的核心方法。本节详细讲解前向传播 (输入数据逐层计算得到输出) 和反向传播 (从输出层反向计算梯度并更新权重) 的完整过程。帮助学生理解链式法则在反向传播中的关键作用，能够描述训练中信息的前向和反向流动。

- 前向传播 (Forward Propagation)：逐层计算的过程

- 损失函数 (Loss Function) : 衡量预测值与真实值差距
- 反向传播 (Backward Propagation) : 基于链式法则的梯度计算
- 权重更新规则: $w = w - \text{learning_rate} * \text{gradient}$

8.3 梯度下降与优化方法

梯度下降是参数优化的基本方法。本节从基本梯度下降讲起,介绍学习率的作用、局部最优与全局最优的区别。重点讲解Adam等动量优化方法的核心思想,帮助学生理解现代优化器与基本梯度下降的差异。

- 梯度下降 (Gradient Descent) : 批量梯度下降、随机梯度下降 (SGD)、小批量梯度下降
- 学习率 (Learning Rate) 的影响: 过大导致震荡、过小导致收敛缓慢
- 局部最优 (Local Optima) 与全局最优 (Global Optima)
- 动量优化方法 (Adam、AdamW) 的核心思想: 结合一阶动量和二阶动量
- Adam与普通梯度下降的差异: 自适应学习率、动量加速

8.4 激活函数、损失函数与决策函数

激活函数为神经网络引入非线性表达能力,损失函数定义优化目标,决策函数确定最终预测结果。本节系统讲解三类函数的定义、数学形式和在神经网络中各自的作用。

- 激活函数 (Activation Function) : ReLU、Sigmoid、Tanh的定义与特性
- 为什么需要激活函数: 非线性变换的重要性
- 损失函数 (Loss Function) : 均方误差 (MSE)、交叉熵 (Cross Entropy)
- 决策函数 (Decision Function) : 如何将模型输出转化为最终预测

8.5 大语言模型概述

大语言模型 (Large Language Model, LLM) 是当前人工智能领域最前沿的技术方向。本节简要介绍大语言模型的核心思想,包括预训练-微调范式、自回归生成、注意力机制等基本概念。帮助学生建立对LLM技术原理的基本认知。

- 大语言模型的核心思想: 从大量文本数据中学习语言规律
- 预训练与微调 (Pre-training & Fine-tuning) 的基本范式
- Transformer架构的核心: 自注意力机制 (Self-Attention)

模块九 卷积神经网络

卷积神经网络（CNN）是计算机视觉领域最重要的深度学习模型，也是NOAI大纲B区重点考查的神经网络架构。本模块从CNN的基本原理出发，系统讲解卷积层、池化层和全连接层的工作机制，帮助学生能够简要描述CNN的网络结构。

9.1 卷积神经网络基本原理

本节从全连接层处理图像的局限性讲起，引入卷积操作的核心思想：局部连接和权重共享。讲解卷积神经网络如何通过层次化的特征提取来实现图像识别任务，帮助学生理解CNN相较于传统方法的独特优势。

- 为什么全连接层不适合处理图像数据
- 卷积操作的核心思想：局部感受野、权重共享、平移不变性
- CNN的整体结构：卷积层 -> 池化层 -> 全连接层

9.2 神经网络常用层的原理与计算

本节详细讲解CNN中三种核心层的原理和计算过程。通过具体数值计算示例，帮助学生理解卷积层如何提取特征、池化层如何降维和增强鲁棒性、全连接层如何完成最终的分类决策。

- 卷积层（Convolutional Layer）：滤波器（卷积核）、步长（Stride）、填充（Padding）、特征图
- 卷积输出的尺寸计算公式： $\text{Output} = (\text{Input} - \text{Kernel} + 2 * \text{Padding}) / \text{Stride} + 1$
- 池化层（Pooling Layer）：最大池化（Max Pooling）与平均池化（Average Pooling）
- 全连接层（Fully Connected Layer）：特征展平与分类决策
- 多通道卷积与多卷积核的操作

模块十 数据处理与可视化工具

本模块对应NOAI大纲C区"进阶计算机技能"的全部要求，系统讲解Numpy、Pandas和Matplotlib三大Python数据处理工具的使用方法。这三大库是第二轮竞赛实践中进行数据处理、分析和可视化的核心工具，也是完成机器学习实验的基础设施。

10.1 NumPy数据处理

NumPy是Python科学计算的核心库，提供高效的多维数组运算。本节从数组的创建和基本操作讲起，系统讲解数组索引、切片、运算、统计函数和形状变换等核心功能，帮助学生掌握NumPy在数据处理中的基本使用方法。

- ndarray对象的创建：从列表创建、zeros、ones、arange、linspace

- 数组运算：逐元素运算、广播机制（Broadcasting）、矩阵运算
- 统计功能：mean、std、min、max、sum、argmax、argmin
- 形状变换：reshape、transpose、flatten、concatenate、stack

10.2 Pandas数据分析

Pandas是Python中最强大的数据分析和处理库。本节系统讲解Pandas的两种核心数据结构（Series和DataFrame），重点掌握数据读取、查询、抽取、融合和缺失值处理等功能。

- DataFrame的创建与基本操作
- 数据读取：read_csv、read_excel等读取方法
- 数据查询与抽取：loc、iloc、条件筛选、布尔索引
- 数据融合：merge、concat、join操作
- 缺失值处理：isnull、dropna、fillna（前向填充等方法）

10.3 Matplotlib数据可视化

数据可视化是理解数据和展示结果的重要手段。本节讲解Matplotlib的核心功能，包括折线图、柱状图、散点图、直方图、饼图等常用图表的绘制方法。通过实际案例帮助学生掌握图表的自定义技巧，使其能够在竞赛中有效地展示数据分析结果。

- 基础图表：折线图（plot）、柱状图（bar）、散点图（scatter）、直方图（hist）
- 图表自定义：标题、坐标轴标签、图例、颜色、线型
- 子图绘制（subplot）与多图布局
- 保存图表与输出格式设置

10.4 特征工程技术

特征工程是将原始数据转化为模型可用的特征表示的关键步骤。本节讲解NOAI大纲C区明确要求的特征工程核心技术，包括滑动窗口、池化操作、编码方法和统计特征提取等。

- 滑动窗口（Sliding Window）：时间序列数据的特征提取
- 池化操作（Pooling）：数据的降维与聚合
- One-hot编码：分类变量的数值化表示
- 统计矩特征提取：均值、标准差、偏度、峰度等
- 基于神经网络的嵌入生成（Embedding）

模块十一 PyTorch深度学习实践

本模块对应NOAI大纲D区中关于PyTorch框架的核心要求，是第二轮竞赛中最关键的实践技能。从张量操作到神经网络定义与训练，再到GPU加速和模型优化，系统讲解PyTorch框架的基本应用，帮助学生能够在文档帮助下独立完成深度学习实验。

11.1 PyTorch基础语法

张量（Tensor）是PyTorch中最基本的数据结构，类似于NumPy的ndarray但支持GPU加速。本节讲解张量的创建、基本运算、数据类型转换，以及与NumPy数组之间的互转操作。

- 张量的创建：torch.tensor、torch.zeros、torch.ones、torch.randn
- 基本运算：加法、乘法、矩阵运算、索引与切片
- 数据类型转换：dtype指定、float()、int()、long()等
- PyTorch张量与NumPy数组的相互转换：.numpy()、from_numpy()
- 自动微分（Autograd）：requires_grad、backward()、grad属性

11.2 神经网络定义与训练

本节讲解使用PyTorch构建和训练神经网络的标准流程。从nn.Module的定义方式出发，讲解前向传播、损失函数、优化器的配置与使用，以及完整的训练循环编写方法。

- nn.Module子类化定义神经网络：__init__和forward方法
- 常用层：nn.Linear、nn.Conv2d、nn.MaxPool2d、nn.ReLU
- 损失函数：nn.MSELoss、nn.CrossEntropyLoss
- 优化器：optim.SGD、optim.Adam、optim.AdamW的配置与使用
- 完整训练循环：前向传播 -> 计算损失 -> 梯度清零 -> 反向传播 -> 参数更新

11.3 CPU与GPU训练

GPU加速是深度学习训练的重要手段。本节讲解CPU与GPU在模型训练中的性能差异，以及如何在PyTorch中实现设备选择、数据迁移和混合精度训练的基础配置。

- CPU与GPU训练模型的性能差异分析
- 设备选择：torch.device("cuda")、torch.cuda.is_available()
- 数据与模型的设备迁移：.to(device)
- 混合精度训练（Mixed Precision Training）的基础配置

11.4 权重初始化与批量归一化

合理的权重初始化和批量归一化是训练深度神经网络的重要技巧。本节讲解Xavier初始化和He初始化的原理，以及批量归一化（Batch Normalization）如何加速训练收敛并提高模型稳定性。

- 权重初始化的重要性：避免梯度消失和梯度爆炸
- Xavier初始化：适用于Sigmoid/Tanh激活函数
- He初始化：适用于ReLU激活函数
- 批量归一化（Batch Normalization）的原理：在层间标准化
- 在PyTorch中使用nn.BatchNorm1d/2d

11.5 RNN与GAN基础

循环神经网络（RNN）和生成对抗网络（GAN）是深度学习中的两个重要模型类别。本节简要介绍RNN处理序列数据的机制，以及GAN通过生成器和判别器对抗训练来生成新样本的核心思想。

- 循环神经网络（RNN）的基本结构：隐藏状态、时间步展开
- 生成对抗网络（GAN）：生成器（Generator）与判别器（Discriminator）的对抗训练
- GAN的应用场景：图像生成、数据增强

模块十二 计算机视觉

本模块对应NOAI大纲D区中关于计算机视觉的要求，涵盖图像分割、特征提取和目标检测三大核心任务。帮助学生理解计算机视觉的基本概念和方法，并使用OpenCV等工具完成相关实验。

12.1 图像分割（Image Segmentation）

图像分割是将图像划分为若干具有语义意义的区域的任务。本节介绍语义分割、实例分割和全景分割的区别，讲解U-Net等经典分割网络的基本结构，帮助学生理解图像分割任务的目标和常用方法。

- 语义分割（Semantic Segmentation）：像素级类别预测
- 实例分割（Instance Segmentation）：区分不同实例
- U-Net网络结构概述

12.2 目标检测（Object Detection）

目标检测是在图像中定位并识别多个目标的任务。本节介绍目标检测的基本概念，包括边界框（Bounding Box）、锚框（Anchor）、非极大值抑制（NMS）等关键技术，以及YOLO和SSD等经典检测算法的核心思想。

- 目标检测的基本概念：边界框、类别预测、置信度

- YOLO (You Only Look Once) 的核心思想：单阶段检测
- SSD (Single Shot Detector) 的多尺度特征检测

12.3 特征提取 (Feature Extraction)

特征提取是从原始图像中获取有意义表示的过程。本节讲解手工特征 (HOG、SIFT) 和深度特征 (CNN特征图、预训练模型特征) 的基本概念，以及迁移学习如何利用预训练模型进行高效的特征提取。

- 手工特征与深度学习特征的区别
- 使用预训练模型 (如ResNet) 进行特征提取
- 迁移学习 (Transfer Learning) 的基本思想与方法
- OpenCV基础操作：图像读取、颜色转换、边缘检测

模块十三 自然语言处理

本模块对应NOAI大纲D区中关于自然语言处理 (NLP) 的要求，涵盖文本预处理、词法分析、文本分类和词嵌入等核心技术。帮助学生在PyTorch框架中独立完成NLP相关实验。

13.1 文本预处理与词法分析

文本预处理是NLP任务的第一步，包括分词 (Tokenization)、清洗和标准化等步骤。本节讲解中英文文本预处理的常用方法，以及词汇表 (Vocabulary) 的构建过程。

- 文本预处理 (Text Preprocessing)：分词、去停用词、大小写转换
- Tokenization：将文本切分为token序列
- 词汇表构建 (Vocabulary Building)：token到索引的映射
- 词法分析 (Lexical Analysis)：词性标注、命名实体识别概述

13.2 文本分类与词嵌入

文本分类是NLP中最基础的任务之一。本节从传统方法 (词袋模型、TF-IDF) 讲起，逐步引入词嵌入 (Word Embedding) 的概念，包括Word2Vec和GloVe等预训练词向量的基本思想。然后讲解使用神经网络进行文本分类的方法。

- 文本分类 (Text Classification) 的基本流程
- 词嵌入 (Word Embedding)：将词映射为稠密向量
- Word2Vec：CBOW模型与Skip-gram模型
- GloVe：基于全局词频统计的词向量
- 在PyTorch中使用nn.Embedding层

13.3 Transformer与预训练模型

Transformer架构是当前NLP领域的主流模型结构。本节简要介绍自注意力机制（Self-Attention）的核心思想，以及基于Transformer的预训练模型（BERT、GPT等）的基本概念。

- 自注意力机制（Attention Mechanism）：Query、Key、Value的计算
- Transformer架构概述：编码器-解码器结构
- 预训练NLP模型：BERT（双向编码）、GPT（自回归生成）
- 微调（Fine-tuning）的基本方法

模块十四 语音处理与大语言模型

本模块对应NOAI大纲D区中关于语音处理和生成式人工智能的最终要求。涵盖语音信号处理的基本概念、大语言模型的应用部署，以及多模态AI的前沿知识。帮助学生了解AI技术在不同模态（语音、文本、图像）上的应用方法。

14.1 语音信号处理

语音信号处理是人工智能在语音领域应用的基础。本节介绍语音信号的数字化表示、特征提取方法（如MFCC），以及语音识别和语音合成的基本概念。

- 语音信号处理（Speech Signal Processing）：采样率、量化、时频分析
- 语音特征提取：MFCC（梅尔频率倒谱系数）、语谱图
- 语音识别（Speech Recognition, ASR）：将语音转化为文本
- 语音合成（Text to Speech, TTS）：将文本转化为语音

14.2 生成式人工智能与大语言模型

生成式人工智能（Generative AI）是当前AI发展最活跃的方向。本节系统介绍大语言模型（LLM）的原理、多模态概念，以及如何实际应用生成式AI模型解决生活中的问题。

- 生成式人工智能（Generative AI）的原理：自回归生成、扩散模型
- 多模态（Multi-modal）AI的概念：文本+图像+语音的联合理解与生成
- 开源预训练语言模型（如Qwen）的本地部署流程
- API调用方法（如使用Openrouter进行调用）
- 使用LLM完成文本生成、问答等基础任务

14.3 综合实践与竞赛模拟

本节通过综合实践项目将所有模块的知识串联起来，包括完整的机器学习项目流程（数据预处理、特征工程、模型训练、评估优化）和模拟竞赛训练。帮助学生将所学知识融会贯通，在竞赛中能够灵活运用各种技术解决实际问题。

- 完整ML项目流程实践：数据处理 -> 特征工程 -> 模型训练 -> 评估
- PyTorch项目实战：从数据加载到模型部署的完整流程
- 历年真题解析与模拟考试
- 竞赛策略与时间管理
- 团队协作与项目管理技巧